

Projekt 4: Napredno sledenje

Ema Leila Grošelj

I. UVOD

Uporabila sem Kalmanov filter za modeliranje naključnega sprehoda, modela s skoraj konstantno hitrostjo in modela s skoraj konstantnim pospeškom. Implementirala sem particle filter in ga testirala na različnih parametrih.

II. PREIZKUSI

A. Kalmanov filter

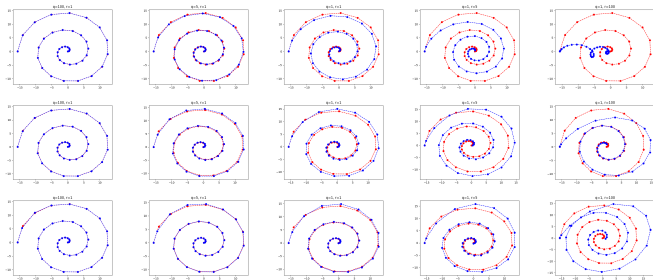


Figure 1: RW (zgoraj), NCV (na sredini), NCA (spodaj), za različne q in r

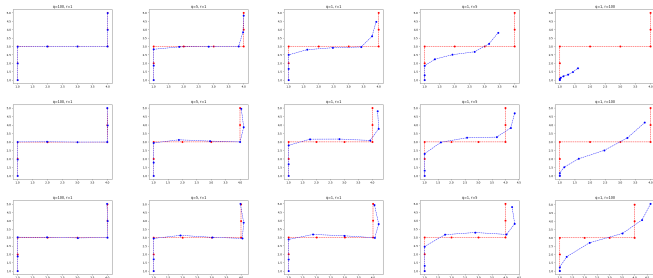


Figure 2: RW (zgoraj), NCV (na sredini), NCA (spodaj), za različne q in r

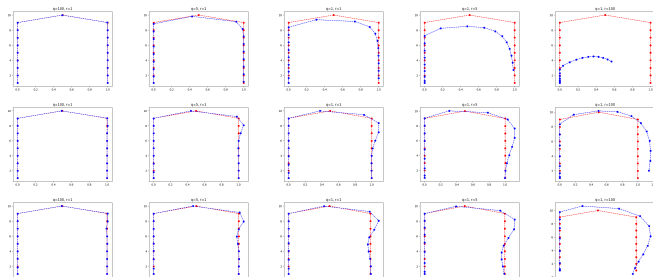


Figure 3: RW (zgoraj), NCV (na sredini), NCA (spodaj), za različne q in r

RW model ni najbolj primeren za nobeno od situacij 1, 2 in 3, saj imamo v vseh situacijah nek trend, RW pa predpostavlja, da trenda ni. Na slikah se pokaže kot zaostajanje za meritvami. Ta model gibanja teži, k temu, da ostanemo na mestu, medtem ko ga meritve le malo premikajo naprej.

Medtem NCV teži k konstantni hitrosti, to je k premikanju naravnost. To se dobro vidi na slikah, kjer model teži k bolj blagim kotom kot so meritve.

Medtem NCA, ki je med drugim tudi bolj računsko zahteven, ni tudi nujno boljši. To vidimo recimo na sliki 3, kjer NCA skoraj pretirava v zavoju (overshoot). Ima nekako prevelik pospešek in ga odnese še dlje od resnične črte. To je zato, ker ta model teži k kroženju.

Kar je skupno vsem modelom v vseh situacijah, je da na začetku zaostajajo. To pa je zato, ker začnemo v stanju, kjer sta tako hitrost kot pospešek enaka 0.

Komentiramo lahko tudi vrednosti parametrov q in r , ki predstavljata varianco dinamičnega modela in meritev. Tako kot so zastavljene situacije je varianca modela meritev (v odvisnosti od r) enaka 0, če rečemo, da so meritve točne. Lahko pa si zlahka zamislimo model, kjer bi bila ne ničelna tj. točke razmetane okoli pike z bolj goste znotraj in vedno bolj redke na ven. Po drugi strani pa q predstavlja varianco dinamičnega modela z neko verjetnostjo dopušča večje ali manjše odklone v izbrani količini. Ta količina je v primeru RW hitrost, v primeru NCV pospešek, v primeru NCA pa sprememba pospeška. Glede na slike bi rekla, tem večji je q , tem manj je model tog.

B. Particle filter

Particle filter sem testirala na več kombinacijah parametrov. Tokrat bolj kot pri kakšni drugi nalogi se je pokazala odvisnost med parametri, to pomeni, da ni bilo dovolj, da požrešno nastavim vse parametre (glede na rezultate analize variacije le enega parametra naenkrat). Veliko poskušanja me je pripeljalo do "najboljšega" rezultata 97 failov z 0.40 overlapom na 6 slikah iz VOT2013. Na Sliki 4 predstavljam omenjene analize variacije le enega elementa.

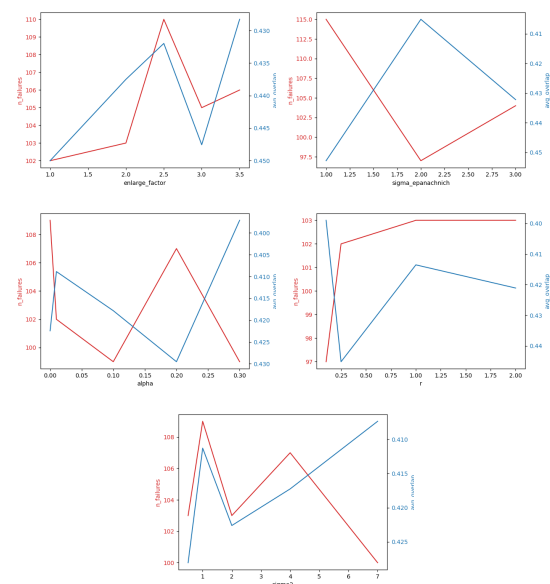


Figure 4: Particle filter: variacija posameznih parametrov. Ostali parametri so prikazani na slikah 5 in 6.

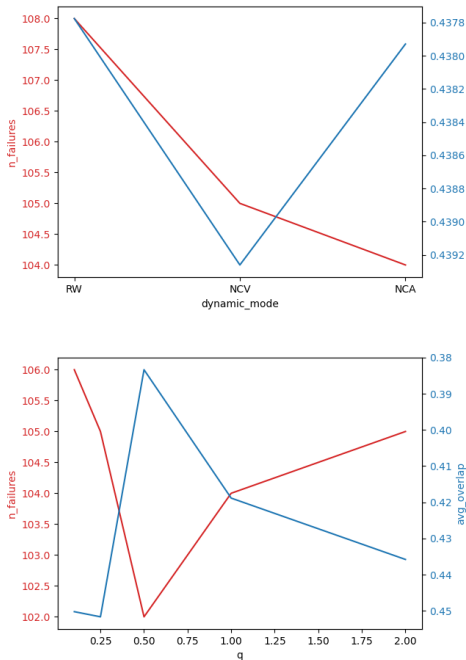


Figure 5: Particle filter: različni modeli premikanja (zgoraj) in različne vrednosti q spodaj.

Na Sliki 5 zgoraj sem predstavila rezultat pri različnih modelih premikanja. Pričakovala sem, da se bo NCA najbolj sposoben prilagoditi premikanju in se zato najboljše odrežal. Nisem pa vedela koliko po NCV modelu pomagalo dejstvo, da sem parametre nastavljala glede na njega. Izkazalo se je, da je za en fail razlike bil boljši NCA.

Na Sliki 5 spodaj sem predstavila vpliv parametra q na uspešnost sledenja. Regulirala sem ga tako kot druge parametre. Njegova nastavitve je zelo odvisna od $alpha$, od r ... Sem pa upoštevala v navodilih omenjeno odvisnost od velikosti targeta tako, da je moj "resnični q " v bistvu enak $q_{parameter} * (visina + sirina)/2$. Na koncu sem ga na stavila na 0.25, a kot vidimo so možne spremembe (vendar so take male spremembe - 4 faili - tudi mogoče zaradi naključnosti, kar še oteži nastavljanje parametrov). Zaradi povedanega in zaradi majhnega števila zaporedij, ki sem ga vključila, težko kaj sklepam iz variacije q . Kako pa naj bi q v teoriji vplival na sledenje pa je opisano pri Kalmanovem filtru.

Če lahko kaj rečemo, glede na to, da je sprememba števila failov (7) in overlapa (0.05) minorna in bi to z lahkoto pripisali naključnosti, potem večje število delcev pozitivno vpliva na število failov, obratno pa velja za overlap. To se, da razbrati iz slike 6. Pričakovano se hitrost v FPS z številom delcev zmanjšuje, ampak tudi ne drastično.

III. DODATEK

Particle filter sem preizkusila tudi na različnih barvnih prostorih: BGR, HSV, HS, YCbCr, Lab. Za to nalogo sem se tudi odločila povečati število testnih zaporedij in sicer na celoten VOT2013. Iz grafa na Sliki 7 vidimo, da nekaj vpliva je. Pri HSV lahko recimo opazimo, da se najslabše odreže pri številu failov in najboljše pri overlapu (zanimivo). Ker je razlika pri overlapu minorna, bi za najboljšega določila YCbCr.

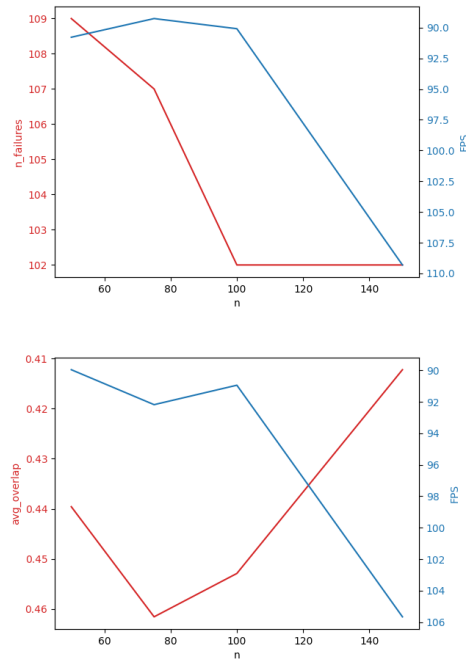


Figure 6: Particle filter: različno število delcev. Število failov in FPS (zgoraj) in overlap in FPS (spodaj).




Figure 7: Particle filter: različni barvni prostori.

IV. ZAKLJUČEK

Moja implementacija ni ne vem kaj, mi je pa vseh princip uporabe verjetnosti pri sledenju, ki bi moral sigurno izboljšati prejšnje filtre. Je dobrodošla nadgradnja.

V. DOPOLNITEV

$$\begin{bmatrix} x \\ y \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ \begin{bmatrix} Tq & 0 \\ 0 & Tq \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Figure 8: RW:
s,F,A,L,
Q,C

$$\begin{bmatrix} x \\ y \\ \dot{x} \\ \dot{y} \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ \begin{bmatrix} \frac{T^3 q}{3} & 0 & \frac{T^2 q}{2} & 0 \\ 0 & \frac{T^3 q}{3} & 0 & \frac{T^2 q}{2} \\ \frac{T^2 q}{2} & 0 & Tq & 0 \\ 0 & \frac{T^2 q}{2} & 0 & Tq \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

Figure 9: NCV:
s,F,A,L,
Q,C

$$\begin{bmatrix} x \\ y \\ \dot{x} \\ \dot{y} \\ \ddot{x} \\ \ddot{y} \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & T & 0 & \frac{T^2}{2} & 0 \\ 0 & 1 & 0 & T & 0 & \frac{T^2}{2} \\ 0 & 0 & 1 & 0 & T & 0 \\ 0 & 0 & 0 & 1 & 0 & T \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ \begin{bmatrix} \frac{T^5 q}{20} & 0 & \frac{T^4 q}{8} & 0 & \frac{T^3 q}{6} & 0 \\ 0 & \frac{T^5 q}{20} & 0 & \frac{T^4 q}{8} & 0 & \frac{T^3 q}{6} \\ \frac{T^4 q}{8} & 0 & \frac{T^3 q}{3} & 0 & \frac{T^2 q}{2} & 0 \\ 0 & \frac{T^4 q}{8} & 0 & \frac{T^3 q}{3} & 0 & \frac{T^2 q}{2} \\ \frac{T^3 q}{6} & 0 & \frac{T^2 q}{2} & 0 & Tq & 0 \\ 0 & \frac{T^3 q}{6} & 0 & \frac{T^2 q}{2} & 0 & Tq \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Figure 10: NCA:
s,F,A,L,
Q,C